

Los datos son tablas

¿Cómo se ve una base de datos por dentro?

Emiliano Miranda González

Instituto Tecnológico Autónomo de México
Departamento Académico de Ciencia Política

Sesión 2 de 11

ITAM, otoño 2026

¿POR QUÉ NOS IMPORTA ESTO?

¿Cómo se ve una base de datos por dentro?

La sesión pasada sacamos un gráfico de una base electoral sin mirar todavía qué había adentro. Antes de pedirle cualquier cosa a una tabla, hay que saber leerla.

De dónde venimos

- Sabemos dónde está parado R y usamos `here()` para las rutas.

De dónde venimos

- Sabemos dónde está parado R y usamos `here()` para las rutas.
- Guardamos cosas en objetos y operamos sobre un vector completo de un golpe.

De dónde venimos

- Sabemos dónde está parado R y usamos `here()` para las rutas.
- Guardamos cosas en objetos y operamos sobre un vector completo de un golpe.
- Ya abrimos `presidencial_2024_entidad.csv` una vez, para graficarlo.

De dónde venimos

- Sabemos dónde está parado R y usamos `here()` para las rutas.
- Guardamos cosas en objetos y operamos sobre un vector completo de un golpe.
- Ya abrimos `presidencial_2024_entidad.csv` una vez, para graficarlo.

Hoy volvemos a esa misma base, pero para mirarla por dentro antes de tocar nada más.

Una tabla no es una hoja de cálculo

Traer una base de verdad

NA: lo que falta, y por qué importa

La unidad de observación

Dos formatos más, para cuando los necesites

Ejercicio

Cada fila es un caso, cada columna es una variable

- En una hoja de cálculo se puede escribir cualquier cosa en cualquier celda: un número aquí, una fecha allá.

Cada fila es un caso, cada columna es una variable

- En una hoja de cálculo se puede escribir cualquier cosa en cualquier celda: un número aquí, una fecha allá.
- R guarda una tabla distinto: como un **tibble**. Cada fila es una observación; cada columna, una variable.

Cada fila es un caso, cada columna es una variable

- En una hoja de cálculo se puede escribir cualquier cosa en cualquier celda: un número aquí, una fecha allá.
- R guarda una tabla distinto: como un **tibble**. Cada fila es una observación; cada columna, una variable.
- Dentro de una columna, todo el dato tiene el mismo tipo, de arriba a abajo.

Cada fila es un caso, cada columna es una variable

- En una hoja de cálculo se puede escribir cualquier cosa en cualquier celda: un número aquí, una fecha allá.
- R guarda una tabla distinto: como un **tibble**. Cada fila es una observación; cada columna, una variable.
- Dentro de una columna, todo el dato tiene el mismo tipo, de arriba a abajo.

Por qué importa esa restricción

Es lo que permite pedirle a R `mean(columna)` con la confianza de que no se va a topar con texto a la mitad donde esperaba un número.

Una tabla no es una hoja de cálculo

Traer una base de verdad

NA: lo que falta, y por qué importa

La unidad de observación

Dos formatos más, para cuando los necesites

Ejercicio

Lo que ya conoces, otra vez

```
resultados <- read_csv(  
  here("datos", "limpios",  
        "presidencial_2024_entidad.csv"))
```

Lee con calma lo que aparece en la consola: es la **especificación de columnas**, y no es un error.

Busca `clave_entidad`: tiene que salir `<chr>`. Si saliera número, "01" se habría convertido en 1.

Dos funciones que se parecen y no son iguales

- `read_csv()`, con guion bajo, del paquete `readr`.

Dos funciones que se parecen y no son iguales

- `read_csv()`, con guion bajo, del paquete `readr`.
- `read.csv()`, con punto, de R base.

Dos funciones que se parecen y no son iguales

- `read_csv()`, con guion bajo, del paquete `readr`.
- `read.csv()`, con punto, de R base.

El salto

`read.csv()` adivina los tipos en silencio y convierte texto en factor sin avisar. `read_csv()` regresa un tibble y dice, línea por línea, que decidió. En este curso usamos siempre `read_csv()`.

glimpse(): conocer una base de un vistazo

```
| glimpse(resultados)
```

`head()` enseña las primeras filas. `glimpse()` gira la tabla de lado: cada columna cabe en una línea, con su tipo y sus primeros valores.

Es lo primero que corres al abrir cualquier base nueva.

Los tipos que vas a ver todo el curso

Abreviación	Qué es	Ejemplo politológico
<code><chr></code>	texto	entidad, nombre de partido
<code><dbl></code>	número con decimales	porcentaje de votos
<code><int></code>	número entero	conteo de escaños
<code><lgl></code>	lógico	TRUE / FALSE
<code><fct></code>	factor, con categorías fijas	nivel de escolaridad

No se puede promediar una columna `<chr>`, ni ordenar de mayor a menor una columna `<lgl>`. El tipo decide qué preguntas se le pueden hacer a cada columna.

Una trampa real

```
mean(resultados$entidad)
```

argument is not numeric or logical: returning NA

Traducción: "este argumento no es numérico ni lógico: voy a regresar NA".

R no truena, y eso es lo peligroso: si no se lee la consola, un **NA** se puede quedar metido en un script largo sin que nadie sepa de dónde salió.

Una tabla no es una hoja de cálculo

Traer una base de verdad

NA: lo que falta, y por qué importa

La unidad de observación

Dos formatos más, para cuando los necesites

Ejercicio

NA no es lo mismo que cero

- NA quiere decir "no disponible": R no sabe qué valor va ahí.

NA no es lo mismo que cero

- NA quiere decir "no disponible": R no sabe qué valor va ahí.
- No es lo mismo que 0, que sí es un valor y dice algo.

NA no es lo mismo que cero

- NA quiere decir "no disponible": R no sabe qué valor va ahí.
- No es lo mismo que 0, que sí es un valor y dice algo.
- No es lo mismo que "", una cadena vacía, que también es un valor.

NA no es lo mismo que cero

- NA quiere decir "no disponible": R no sabe qué valor va ahí.
- No es lo mismo que 0, que sí es un valor y dice algo.
- No es lo mismo que "", una cadena vacía, que también es un valor.

R los trata distinto a propósito: no hay que confundir "no hay información" con "la información es cero".

Un vector con un hueco

```
edad <- c(35, NA, 42, 29)

is.na(edad)
sum(is.na(edad))

mean(edad)                                # que crees que va a pasar?
mean(edad, na.rm = TRUE)
```

Un solo **NA** vuelve **NA** cualquier operación sobre todo el vector. `na.rm = TRUE` le dice a R que lo ignore.

Un caso real, no inventado

En la base municipal de la elección de 2024 hay dos municipios de Oaxaca con NA en el porcentaje de cada coalición.

- No es un error de captura: ninguna casilla se instaló ese día.

Un caso real, no inventado

En la base municipal de la elección de 2024 hay dos municipios de Oaxaca con NA en el porcentaje de cada coalición.

- No es un error de captura: ninguna casilla se instaló ese día.
- Dividir votos entre cero no tiene sentido.

Un caso real, no inventado

En la base municipal de la elección de 2024 hay dos municipios de Oaxaca con NA en el porcentaje de cada coalición.

- No es un error de captura: ninguna casilla se instaló ese día.
- Dividir votos entre cero no tiene sentido.
- La base honesta dice NA en vez de inventar un 0.

Una tabla no es una hoja de cálculo

Traer una base de verdad

NA: lo que falta, y por qué importa

La unidad de observación

Dos formatos más, para cuando los necesites

Ejercicio

La pregunta que ningún `glimpse()` contesta sola

¿Qué representa una fila de esta tabla?

- ¿Puede repetirse la misma unidad en dos filas distintas?

La pregunta que ningún `glimpse()` contesta sola

¿Qué representa una fila de esta tabla?

- ¿Puede repetirse la misma unidad en dos filas distintas?
- ¿Esta base es una foto de un instante, o sigue a alguien en el tiempo?

Dos formas de armar una tabla

Corte transversal — una foto

entidad	participación
Aguascalientes	60.6
Baja California	48.7
Campeche	64.6

Un solo momento, muchas entidades.

Serie de tiempo — película de una

año	participación
2012	63
2018	63
2024	61

Cifras inventadas, para ver la forma.

Dos formas más

Pooled — fotos sueltas

año	entidad	partic.
2012	Sonora	58
2018	Puebla	61
2024	Yucatán	66

Nadie se repite a propósito.

Panel — película de varias

entidad	2018	2024
Sonora	58	60
Puebla	61	59

Las mismas unidades, año tras año.

¿Foto o película?

El salto

De "¿cuántas filas tiene mi base?" a "¿qué representa cada fila, y puede repetirse?". Una foto compara entidades entre sí; una película compara una entidad consigo misma a través del tiempo. Esa sola pregunta decide qué se puede contestar con la tabla que tienes enfrente.

Vamos a volver a esta distinción en la sesión 4, cuando comparemos "entre" con "dentro de".

La misma clase de dato, otra unidad de observación

```
municipios <- read_csv(  
  here("datos", "limpios",  
        "puente_claves_ine_inegi.csv"))  
  
nrow(resultados)    # 32  
nrow(municipios)     # 2477
```

Mismo país, misma clave de entidad. Cambiar la unidad de observación multiplicó las filas por casi 80.

Una tabla no es una hoja de cálculo

Traer una base de verdad

NA: lo que falta, y por qué importa

La unidad de observación

Dos formatos más, para cuando los necesites

Ejercicio

Excel y Stata, en dos minutos

```
library(readxl)    # para .xlsx
library(haven)     # para .dta (Stata)

# read_excel(here("datos", "limpios",
#               "algun_archivo.xlsx"))
# read_dta(here("datos", "limpios",
#               "algun_archivo.dta"))
```

No los corremos hoy: en este repositorio los datos limpios viven como .csv y .rds. La sintaxis queda aquí para cuando la necesites.

Lo que muerde la primera vez

- `read_excel()` lee la primera hoja por default; usa `sheet = ...` si hay varias.

Lo que muerde la primera vez

- `read_excel()` lee la primera hoja por default; usa `sheet = ...` si hay varias.
- Un `.dta` trae etiquetas de valor que R no siempre traduce solo: prueba `as_factor()`.

Lo que muerde la primera vez

- `read_excel()` lee la primera hoja por default; usa `sheet = ...` si hay varias.
- Un `.dta` trae etiquetas de valor que R no siempre traduce solo: prueba `as_factor()`.
- Un Excel de gobierno casi siempre trae nombres de columna sucios. `clean_names()`, del paquete `janitor`, los deja en `snake_case` de un golpe.

Una tabla no es una hoja de cálculo

Traer una base de verdad

NA: lo que falta, y por qué importa

La unidad de observación

Dos formatos más, para cuando los necesites

Ejercicio

Quince minutos, tres niveles

- **Calentamiento** — vuelve a cargar el puente de claves y corre `glimpse()` sobre él.
- **De verdad** — abre la base municipal de 2024, nunca vista en clase, y cuenta sus `NA` reales.
- **Si te sobra tiempo** — investiga la diferencia entre `NA` y `NULL`, y verifícala corriendo código.

El archivo es `02_ejercicio.R`. La solución se publica al terminar la sesión.

Lo que ya sabemos hacer

- Importar una base con `read_csv()` y leer lo que R dice al hacerlo.
- Usar `glimpse()` para reconocer los tipos de variable de una base nueva.
- Contestar, de cualquier tabla, qué representa una fila y si puede repetirse.

LA SEMANA QUE VIENE

Pedirle cosas a los datos

Vamos a conocer el pipe `|>` y los verbos que más vamos a usar en todo el curso: `filter()`, `select()`, `arrange()` y `mutate()`. La pregunta que la mueve: ¿dónde ganó Morena por más de veinte puntos?