

Agrupar, resumir, cruzar

¿Cómo comparo estados entre sí?

Emiliano Miranda González

Instituto Tecnológico Autónomo de México
Departamento Académico de Ciencia Política

Sesión 4 de 11

ITAM, otoño 2026

¿POR QUÉ NOS IMPORTA ESTO?

¿Cómo comparo estados entre sí?

Sientes que unas regiones votaron distinto que otras y que el tamaño de un municipio importa. Hoy conviertes esas dos intuiciones en un número —y ves, en vivo, cómo un cruce de datos se rompe y cómo se arregla.

De dónde venimos

- El pipe `|>` encadena pasos sin que ninguno destruya la base.

De dónde venimos

- El pipe `|>` encadena pasos sin que ninguno destruya la base.
- `filter()`, `select()`, `arrange()` y `mutate()` trabajan fila por fila, o columna por columna.

De dónde venimos

- El pipe `|>` encadena pasos sin que ninguno destruya la base.
- `filter()`, `select()`, `arrange()` y `mutate()` trabajan fila por fila, o columna por columna.
- Hoy, por primera vez, vamos a colapsar muchas filas en una sola por grupo.

Resumir: la trampa de la sesión 1

count(): contar sin rodeos

El left_join() que se rompe, a propósito

pivot_longer(): acomodar columnas

El entregable

Ejercicio

Dos números que no cuadraban

En la sesión 1 calculamos esto y lo dejamos sin resolver del todo:

- `mean(resultados$pct_shh)` — el promedio simple de 32 porcentajes.

Dos números que no cuadraban

En la sesión 1 calculamos esto y lo dejamos sin resolver del todo:

- `mean(resultados$pct_shh)` — el promedio simple de 32 porcentajes.
- `sum(votos_shh) / sum(total_votos) * 100` — el ponderado.

Dos números que no cuadraban

En la sesión 1 calculamos esto y lo dejamos sin resolver del todo:

- `mean(resultados$pct_shh)` — el promedio simple de 32 porcentajes.
- `sum(votos_shh) / sum(total_votos) * 100` — el ponderado.
- Los dos salen distintos, y nos quedamos con la desconfianza.

Dos números que no cuadraban

En la sesión 1 calculamos esto y lo dejamos sin resolver del todo:

- `mean(resultados$pct_shh)` — el promedio simple de 32 porcentajes.
- `sum(votos_shh) / sum(total_votos) * 100` — el ponderado.
- Los dos salen distintos, y nos quedamos con la desconfianza.

Hoy tenemos la herramienta para repetir esa cuenta cuantas veces haga falta.

group_by() + summarise()

```
resultados_entidad |>
  group_by(region) |>
  summarise(
    pct_simple      = mean(pct_shh),
    pct_ponderado = 100 * sum(votos_shh) / sum(total_votos)
  )
```

`group_by()` no cambia ni una celda: solo marca por dónde vas a resumir. `summarise()` colapsa cada grupo en una sola fila.

Una región no es un dato del INE

```
resultados_entidad <- resultados_entidad |>
  mutate(region = case_when(
    entidad %in% c("Chihuahua", "Sonora")
      ~ "Noroeste",
    entidad %in% c("Coahuila", "Tamaulipas")
      ~ "Noreste",
    # ... tres grupos mas, en el script completo
  ))
```

- `case_when()` prueba condiciones en orden y asigna la primera que se cumple.

Una región no es un dato del INE

```
resultados_entidad <- resultados_entidad |>
  mutate(region = case_when(
    entidad %in% c("Chihuahua", "Sonora")
      ~ "Noroeste",
    entidad %in% c("Coahuila", "Tamaulipas")
      ~ "Noreste",
    # ... tres grupos mas, en el script completo
  ))
```

- `case_when()` prueba condiciones en orden y asigna la primera que se cumple.
- Cinco regiones, decisión nuestra, documentada como tal —no hay una regionalización oficial única.

Simple contra ponderado, por región

Región	pct_simple	pct_ponderado
Sur-sureste	70.22	70.29
Noroeste	61.27	61.58
Centro	63.57	60.84
Noreste	53.75	52.37
Occidente y Bajío	52.12	50.08

En Centro, la brecha es la más grande: Ciudad de México y México concentran millones de votos que el promedio simple trata igual que los de Tlaxcala.

Cerramos la trampa de la sesión 1

El salto

De «el país votó como 60 y tantos por ciento» a poder decirlo con precisión: el promedio simple de las 32 entidades es 60.66%, el ponderado real es 59.76%. La diferencia es, exactamente, el peso que un promedio simple le regala a los estados chicos.

Entre grupos, no dentro de un grupo

- `group_by()` + `summarise()` compara **entre** grupos: esta región contra esa otra.

Entre grupos, no dentro de un grupo

- `group_by()` + `summarise()` compara **entre** grupos: esta región contra esa otra.
- Comparar un mismo estado consigo mismo a través del tiempo es otra pregunta —se llama comparación *within* en datos de panel.

Entre grupos, no dentro de un grupo

- `group_by()` + `summarise()` compara **entre** grupos: esta región contra esa otra.
- Comparar un mismo estado consigo mismo a través del tiempo es otra pregunta —se llama comparación *within* en datos de panel.
- Hoy solo hay una elección: hoy comparamos *between*. El resto queda para el extra de panel y efectos fijos.

Resumir: la trampa de la sesión 1

count(): contar sin rodeos

El left_join() que se rompe, a propósito

pivot_longer(): acomodar columnas

El entregable

Ejercicio

El atajo de todos los días

```
resultados_municipio |>  
  count(entidad, sort = TRUE)
```

Lo mismo que `group_by() + summarise(n = n())`, en una sola línea. `sort = TRUE` ordena de mayor a menor.

Oaxaca, otra vez

- Oaxaca tiene más de 500 municipios: casi una cuarta parte de todos los del país.

Oaxaca, otra vez

- Oaxaca tiene más de 500 municipios: casi una cuarta parte de todos los del país.
- No es un capricho de los datos.

Oaxaca, otra vez

- Oaxaca tiene más de 500 municipios: casi una cuarta parte de todos los del país.
- No es un capricho de los datos.
- Va a regresar, peor, en la sesión 7: un mapa «por cantidad» sin ajustar por población hace ver que Oaxaca domina el mapa entero.

Resumir: la trampa de la sesión 1

count(): contar sin rodeos

El left_join() que se rompe, a propósito

pivot_longer(): acomodar columnas

El entregable

Ejercicio

La pregunta de hoy

Tenemos la base electoral municipal y el puente de claves INE-INEGI.

- ¿Los cruzamos por el **nombre** del municipio?

La pregunta de hoy

Tenemos la base electoral municipal y el puente de claves INE-INEGI.

- ¿Los cruzamos por el **nombre** del municipio?
- Es la primera idea que se le ocurre a cualquiera.

La pregunta de hoy

Tenemos la base electoral municipal y el puente de claves INE-INEGI.

- ¿Los cruzamos por el **nombre** del municipio?
- Es la primera idea que se le ocurre a cualquiera.
- Vamos a intentarla tal cual, a propósito.

El intento por nombre

```
intento_por_nombre <- resultados_municipio |>
  left_join(puente, by = "municipio")

nrow(resultados_municipio)    # 2475
nrow(intento_por_nombre)      # ?
```

R sí devuelve un resultado. Antes, avisa.

Cuando algo falla

Warning: unexpected many-to-many relationship

Traducción: una fila tuya hizo pareja con **más de una** fila de la otra base. No detiene el código —el resultado sí se produce—, pero es una alarma que hay que leer.

`nrow()` pasó de 2,475 a 2,943. Empezaste con una fila por municipio y terminaste con más.

Diagnóstico con la herramienta que ya sabes

```
resultados_municipio |>  
  count(municipio, sort = TRUE) |>  
  filter(n > 1)
```

89 nombres de municipio no son únicos en México.

Héroes patrios repartidos por el mapa

- «Benito Juárez» —así, sin acento en los datos— es municipio en **siete** entidades distintas.

Héroes patrios repartidos por el mapa

- «Benito Juárez» —así, sin acento en los datos— es municipio en **siete** entidades distintas.
- «Emiliano Zapata» lo es en **seis**.

Héroes patrios repartidos por el mapa

- «Benito Juárez» —así, sin acento en los datos— es municipio en **siete** entidades distintas.
- «Emiliano Zapata» lo es en **seis**.
- Un nombre de municipio, solo, casi nunca es una clave.

La combinación entidad + municipio sí lo es casi siempre; la clave numérica lo es siempre.

Unir por clave, la correcta

```
cruce_correcto <- resultados_municipio |>
  left_join(puente,
    by = c("clave_municipio" = "clave_municipio_inegi"))

nrow(cruce_correcto)    # 2475
```

Sin warning, sin filas de más. La base electoral ya trae la clave de INEGI en `clave_municipio` —compruébalo con Colima capital: "06002", no "06001".

El cruce, resuelto

El salto

De «estas dos bases no cuadran» a saber, con exactitud, en cuáles de los 2,477 municipios se rompe un cruce por nombre —y por qué— y cruzarlas bien por clave.

anti_join(): ¿quién se queda fuera, de verdad?

```
puente |>  
  anti_join(resultados_municipio,  
    by = c("clave_municipio_inegi" = "clave_municipio"))
```

Chicomuselo y Pantelhó, Chiapas. Documentado en [datos/README.md](#) y sin una explicación completa de por qué —está bien decirlo.

Por qué `merge()` está prohibido en este curso

- `merge()` de R base puede perder filas o multiplicarlas, igual que un `left_join()` mal hecho.

Por qué `merge()` está prohibido en este curso

- `merge()` de R base puede perder filas o multiplicarlas, igual que un `left_join()` mal hecho.
- La diferencia es que **nunca avisa**.

Por qué `merge()` está prohibido en este curso

- `merge()` de R base puede perder filas o multiplicarlas, igual que un `left_join()` mal hecho.
- La diferencia es que **nunca avisa**.
- Un cruce que falla en silencio es peor que uno que grita.

Resumir: la trampa de la sesión 1

count(): contar sin rodeos

El left_join() que se rompe, a propósito

pivot_longer(): acomodar columnas

El entregable

Ejercicio

Tres columnas, una sola

```
resultados_entidad |>
  select(entidad, pct_shh, pct_fcm, pct_mc) |>
  pivot_longer(
    cols      = c(pct_shh, pct_fcm, pct_mc),
    names_to  = "coalicion",
    values_to = "pct"
  )
```

32 entidades × 3 coaliciones = 96 filas. El formato que la sesión 5 necesita para graficar.

Y la inversa, en una línea

- `pivot_wider()` hace exactamente lo contrario.

Y la inversa, en una línea

- `pivot_wider()` hace exactamente lo contrario.
- Se usa bastante menos de lo que uno imagina.

Y la inversa, en una línea

- `pivot_wider()` hace exactamente lo contrario.
- Se usa bastante menos de lo que uno imagina.
- Queda en el acordeón de esta sesión y en `extras/`.

Resumir: la trampa de la sesión 1

count(): contar sin rodeos

El left_join() que se rompe, a propósito

pivot_longer(): acomodar columnas

El entregable

Ejercicio

Reconstruir la cifra por entidad

```
resultados_municipio |>  
  group_by(entidad) |>  
  summarise(total_votos_reconstruido = sum(total_votos))
```

Sumamos los 2,475 municipios agrupados por entidad. ¿Cuadra contra `presidencial_2024_entidad.csv`, armado directo por el INE?

Casi cuadra —y la diferencia tiene nombre

Entidad	Diferencia (votos)
Jalisco	16,769
Puebla	9,972
Michoacán	9,288
Guanajuato	9,214

La suma total es 117,831: exactamente el voto en el extranjero, que `presidencial_2024_municipio.csv` excluye por no tener municipio. Los estados con más población fuera del país concentran la diferencia más grande.

Resumir: la trampa de la sesión 1

count(): contar sin rodeos

El left_join() que se rompe, a propósito

pivot_longer(): acomodar columnas

El entregable

Ejercicio

Quince minutos, tres niveles

- **Calentamiento** — el mismo resumen por región, con Movimiento Ciudadano en vez de Sigamos Haciendo Historia.
- **De verdad** — municipios chicos, medianos y grandes: ¿cuál participa más? Y, con el puente, ¿qué entidad tiene más claves distintas entre INE e INEGI?
- **Si te sobra tiempo** — investiga `pivot_wider()` y el argumento `relationship` de los joins, y verifica lo que te conteste una IA corriéndolo.

El archivo es `04_ejercicio.R`. La solución se publica al terminar la sesión.

Lo que ya sabemos hacer

- Resumir una base por el grupo que te interese, con `group_by()` y `summarise()`, y calcular una media ponderada cuando la simple miente.
- Cruzar dos bases con `left_join()`, diagnosticar con `count()` y `anti_join()` cuando el cruce sale mal, y corregirlo cruzando por clave.
- Acomodar columnas en filas con `pivot_longer()` cuando lo que sigue es graficar.

LA SEMANA QUE VIENE

La gramática de los gráficos

Vas a dejar de copiar un `ggplot()` prestado y vas a entender por qué cada capa está donde está —y por qué unos gráficos convencen y otros no.