

Describir sin mentir

¿Qué significa que dos cosas «van juntas»?

Emiliano Miranda González

Instituto Tecnológico Autónomo de México
Departamento Académico de Ciencia Política

Sesión 8 de 11

ITAM, otoño 2026

¿POR QUÉ NOS IMPORTA ESTO?

¿Qué significa que dos cosas «van juntas»?

En la sesión 1 preguntaste si donde vota más gente le va mejor a un bloque político, y la respuesta honesta fue «no puedo afirmar más con lo que sé hoy». Hoy sí puedes.

De dónde venimos

- Ya usaste `mean()` desde la sesión 1, con la participación de las 32 entidades.

De dónde venimos

- Ya usaste `mean()` desde la sesión 1, con la participación de las 32 entidades.
- Ya sabes construir un `geom_point()` desde la sesión 5.

De dónde venimos

- Ya usaste `mean()` desde la sesión 1, con la participación de las 32 entidades.
- Ya sabes construir un `geom_point()` desde la sesión 5.
- Hoy los dos se juntan, y se les suman tres funciones nuevas: `median()`, `sd()` y `cor()`.

Un número, y su primera traición

Qué tan repartidos están

El cuarteto de Anscombe

«Van juntas»

Cuando pocos casos deciden

Ejercicio

Dos maneras de resumir una variable

```
media_lista_nominal <- mean(municipios$lista_nominal)
mediana_lista_nominal <- median(municipios$lista_nominal)
```

Dos maneras de resumir una variable

```
media_lista_nominal <- mean(municipios$lista_nominal)
mediana_lista_nominal <- median(municipios$lista_nominal)
```

No se parecen

La media ronda las 39,700 personas. La mediana apenas roza las 10,400. Son los mismos 2,475 municipios.

La media: un subibaja

- Es el **punto de equilibrio**: donde quedaría el apoyo si pusieras cada municipio en la báscula que le toca.

La media: un subibaja

- Es el **punto de equilibrio**: donde quedaría el apoyo si pusieras cada municipio en la báscula que le toca.
- Alguien muy pesado en un extremo lo inclina por completo.

La media: un subibaja

- Es el **punto de equilibrio**: donde quedaría el apoyo si pusieras cada municipio en la báscula que le toca.
- Alguien muy pesado en un extremo lo inclina por completo.
- Ese peso lo ponen Tijuana, Iztapalapa y Puebla: más de un millón de personas en su lista nominal, cada uno.

La mediana: el de en medio

```
municipios |>  
  filter(lista_nominal < media_lista_nominal) |>  
  nrow()
```

La mediana: el de en medio

```
municipios |>  
  filter(lista_nominal < media_lista_nominal) |>  
  nrow()
```

El salto

Más de ocho de cada diez municipios están por debajo de la media. La media no describe a un municipio típico: describe un punto de equilibrio que casi nadie ocupa.

Un número, y su primera traición

Qué tan repartidos están

El cuarteto de Anscombe

«Van juntas»

Cuando pocos casos deciden

Ejercicio

sd(): una distancia típica al promedio

```
sd_participacion <- sd(municipios$participacion)
sd_lista_nominal <- sd(municipios$lista_nominal)
```

Sin fórmula: entre más apretados estén los datos alrededor del promedio, más chica es; entre más desperdigados, más grande.

Dos variables, dos comportamientos

- Participación: **sd** de apenas 11 puntos, en una escala de 0 a 100. Los municipios se agolpan cerca del promedio.

Dos variables, dos comportamientos

- Participación: **sd** de apenas 11 puntos, en una escala de 0 a 100. Los municipios se agolpan cerca del promedio.
- Lista nominal: **sd** de más de 117,000 —**mayor** que su propia media.

Dos variables, dos comportamientos

- Participación: **sd** de apenas 11 puntos, en una escala de 0 a 100. Los municipios se agolpan cerca del promedio.
- Lista nominal: **sd** de más de 117,000 —**mayor** que su propia media.
- Eso solo le pasa a variables muy desiguales, con una cola larga de casos extremos.

Dos variables, dos comportamientos

- Participación: **sd** de apenas 11 puntos, en una escala de 0 a 100. Los municipios se agolpan cerca del promedio.
- Lista nominal: **sd** de más de 117,000 —**mayor** que su propia media.
- Eso solo le pasa a variables muy desiguales, con una cola larga de casos extremos.

Vas a formalizar esto con una fórmula en tu curso de Estadística; aquí lo viste moverse.

Un número, y su primera traición

Qué tan repartidos están

El cuarteto de Anscombe

«Van juntas»

Cuando pocos casos deciden

Ejercicio

Cuatro conjuntos, diseñados a propósito

Francis Anscombe, 1973. Cuatro conjuntos —I, II, III, IV— con la misma media, la misma desviación estándar en cada variable y, según vas a comprobar en un momento, hasta la misma correlación.

Cuatro conjuntos, diseñados a propósito

Francis Anscombe, 1973. Cuatro conjuntos —I, II, III, IV— con la misma media, la misma desviación estándar en cada variable y, según vas a comprobar en un momento, hasta la misma correlación.

Viene incluido en R, sin instalar nada: `anscombe`.

Los mismos números resumen

```
anscombe_largo |>  
  group_by(conjunto) |>  
  summarise(media_x = mean(x), media_y = mean(y),  
            sd_x = sd(x), sd_y = sd(y))
```

Si solo tuvieras esta tabla, dirías que los cuatro conjuntos son la misma variable, medida cuatro veces.

Ahora gráficálos

```
ggplot(anscombe_largo, aes(x = x, y = y)) +  
  geom_point(colour = lab_colores[["verde_itam"]]) +  
  facet_wrap(~ conjunto) +  
  theme_lab()
```

Sin correr una sola regresión. Hoy se trata de mirar.

Cuatro historias, no una

- I — una recta con ruido. Justo lo que los números resumen prometían.

Cuatro historias, no una

- I — una recta con ruido. Justo lo que los números resumen prometían.
- II — una curva casi perfecta. No una recta.

Cuatro historias, no una

- I — una recta con ruido. Justo lo que los números resumen prometían.
- II — una curva casi perfecta. No una recta.
- III — una recta arruinada por un solo dato atípico.

Cuatro historias, no una

- I — una recta con ruido. Justo lo que los números resumen prometían.
- II — una curva casi perfecta. No una recta.
- III — una recta arruinada por un solo dato atípico.
- IV — sin relación real: un solo punto decide toda la pendiente.

El salto

El salto

De «confío en un número porque lo calculé bien» a «un número resumen puede ser aritméticamente correcto y aun así esconder una historia completamente distinta».

La única defensa es mirar antes de resumir.

Un número, y su primera traición

Qué tan repartidos están

El cuarteto de Anscombe

«Van juntas»

Cuando pocos casos deciden

Ejercicio

Un número entre -1 y 1

- Cerca de 1: cuando una sube, la otra casi siempre sube con ella.

Un número entre -1 y 1

- Cerca de 1: cuando una sube, la otra casi siempre sube con ella.
- Cerca de -1: cuando una sube, la otra casi siempre baja.

Un número entre -1 y 1

- Cerca de **1**: cuando una sube, la otra casi siempre sube con ella.
- Cerca de **-1**: cuando una sube, la otra casi siempre baja.
- Cerca de **0**: no hay ningún patrón en línea recta entre las dos.

Un número entre -1 y 1

- Cerca de **1**: cuando una sube, la otra casi siempre sube con ella.
- Cerca de **-1**: cuando una sube, la otra casi siempre baja.
- Cerca de **0**: no hay ningún patrón en línea recta entre las dos.

`cor()` le pone un número al «tiende» de «cuando una sube, la otra tiende a subir».

Cuidado con el primer intento

```
cor(municipios$participacion, municipios$pct_shh)  
# [1] NA
```

Cuidado con el primer intento

```
cor(municipios$participacion, municipios$pct_shh)  
# [1] NA
```

NA, y no es un error de R

Dos municipios de Oaxaca no tuvieron ninguna casilla instalada; su `pct_shh` quedó en NA. `cor()` no lo ignora solo: hay que pasarle `use = "complete.obs"`.

La respuesta a la pregunta de la sesión 1

```
cor(municipios$participacion, municipios$pct_shh,  
    use = "complete.obs")  
# [1] -0.12
```

Casi nada. Y si acaso, en la dirección contraria a la que «más participación, más apoyo al bloque que gobierna» hubiera adivinado.

La nube, con su línea de tendencia

```
ggplot(municipios, aes(x = participacion, y = pct_shh)) +  
  geom_point(alpha = 0.5) +  
  geom_smooth(method = "lm", se = FALSE) +  
  theme_lab()
```

`geom_smooth()` traza, sin que corras una regresión tú mismo, la recta que mejor resume hacia dónde va la nube.

Dos advertencias que se quedan todo el curso

- Un número de correlación **nunca** dice qué causa qué.

Dos advertencias que se quedan todo el curso

- Un número de correlación **nunca** dice qué causa qué.
- La correlación solo mide qué tan **recta** es una relación.

Dos advertencias que se quedan todo el curso

- Un número de correlación **nunca** dice qué causa qué.
- La correlación solo mide qué tan **recta** es una relación.
- El conjunto II de Anscombe es esa segunda advertencia hecha gráfico: una relación fuerte y real que la correlación no ve.

Un número, y su primera traición

Qué tan repartidos están

El cuarteto de Anscombe

«Van juntas»

Cuando pocos casos deciden

Ejercicio

La misma pregunta, dos unidades de análisis

```
cor(entidades$participacion, entidades$pct_shh)  
# [1] 0.06
```

La misma pregunta, dos unidades de análisis

```
cor(entidades$participacion, entidades$pct_shh)  
# [1] 0.06
```

Ni el signo coincide

Por municipio: -0.12. Por entidad: 0.06. Ambos están tan cerca de cero que agrupar distinto los empuja para el lado contrario.

Los ataques de tiburones

Adrián Lucardi cuenta, en su curso de métodos, un caso sobre ataques de tiburones y una elección de Estados Unidos de 1916 [VERIFICAR la referencia exacta]: con apenas 21 observaciones, un solo criterio de codificación cambiaba el resultado completo del análisis.

Los ataques de tiburones

Adrián Lucardi cuenta, en su curso de métodos, un caso sobre ataques de tiburones y una elección de Estados Unidos de 1916 [VERIFICAR la referencia exacta]: con apenas 21 observaciones, un solo criterio de codificación cambiaba el resultado completo del análisis.

El salto

Entre menos casos tengas, o entre más se pueda discutir cómo agruparlos, más cuidado hay que tener antes de creerte un número.

Un número, y su primera traición

Qué tan repartidos están

El cuarteto de Anscombe

«Van juntas»

Cuando pocos casos deciden

Ejercicio

Quince minutos, tres niveles

- **Calentamiento** — `media`, `mediana` y `sd()` de `pct_fcm` en vez de `lista_nominal`.
- **De verdad** — ¿participación y voto por FCM van juntas? ¿El signo es el opuesto al de SHH?
- **Si te sobra tiempo** — la misma pregunta por entidad, y la pregunta comparada que espera una base de V-Dem.

El archivo es `08_ejercicio.R`. La solución se publica al terminar la sesión.

Lo que ya sabemos hacer

- Calcular media, mediana y desviación estándar de una variable, y explicar cada una sin una sola fórmula.
- Explicar, con el cuarteto de Anscombe, por qué un número resumen nunca sustituye a un gráfico.
- Construir un diagrama de dispersión con línea de tendencia, calcular una correlación e interpretarla en prosa.

LA SEMANA QUE VIENE

La regresión como instrumento politológico

La línea de tendencia de hoy se calculó sola, adentro de `geom_smooth()`. La sesión 9 abre esa caja: `lm()`, `feols()`, y por qué correlación no es lo mismo que causalidad.