

La regresión como instrumento politológico

¿Cuánto explica X a Y?

Emiliano Miranda González

Instituto Tecnológico Autónomo de México
Departamento Académico de Ciencia Política

Sesión 9 de 11

ITAM, otoño 2026

¿POR QUÉ NOS IMPORTA ESTO?

¿Cuánto explica X a Y?

Tienes una nube de puntos y una corazonada de hacia dónde va. Hoy esa corazonada se convierte en un número con unidades, que alguien más puede leer y discutir.

De dónde venimos

- Medimos qué tan dispersos están los datos con la desviación estándar.

De dónde venimos

- Medimos qué tan dispersos están los datos con la desviación estándar.
- Calculamos la correlación entre participación y la ventaja de la coalición: -0.13 . Negativa y débil.

De dónde venimos

- Medimos qué tan dispersos están los datos con la desviación estándar.
- Calculamos la correlación entre participación y la ventaja de la coalición: -0.13 . Negativa y débil.
- Le pusimos a la nube una línea con `geom_smooth(method = "lm")`: hacia dónde va la nube.

De dónde venimos

- Medimos qué tan dispersos están los datos con la desviación estándar.
- Calculamos la correlación entre participación y la ventaja de la coalición: -0.13 . Negativa y débil.
- Le pusimos a la nube una línea con `geom_smooth(method = "lm")`: hacia dónde va la nube.

Hoy esa línea deja de ser un adorno del gráfico. Le vamos a poner nombre y le vamos a sacar sus dos números.

Una recta con nombre

Dos funciones para la misma pregunta

Leer una tabla sin haberla derivado

Un segundo modelo, y la tentación que resistimos

Correlación no es causa

Ejercicio

La nube ya tenía una recta; hoy la nombramos

- Esa línea que dibujó `geom_smooth()` no salió de la nada: hay un método que encuentra, de todas las rectas posibles, la que mejor resume la nube.

La nube ya tenía una recta; hoy la nombramos

- Esa línea que dibujó `geom_smooth()` no salió de la nada: hay un método que encuentra, de todas las rectas posibles, la que mejor resume la nube.
- Se llama **mínimos cuadrados**. Vas a ver cómo se calcula en Estadística; aquí solo la vamos a usar.

La nube ya tenía una recta; hoy la nombramos

- Esa línea que dibujó `geom_smooth()` no salió de la nada: hay un método que encuentra, de todas las rectas posibles, la que mejor resume la nube.
- Se llama **mínimos cuadrados**. Vas a ver cómo se calcula en Estadística; aquí solo la vamos a usar.
- Toda recta tiene dos números: dónde arranca (el **intercepto**) y cuánto sube o baja por cada unidad de x (la **pendiente**).

Ajustar la recta: `lm()`

```
modelo_1 <- lm(ventaja_shh ~ participacion,  
               data = municipios)  
  
summary(modelo_1)
```

La formula se lee "ventaja_shh en funcion de participacion". A la izquierda del ~ va lo que quieres explicar; a la derecha, con qué.

Dos números, siempre con unidades

- El **Intercept**: la ventaja que predice el modelo cuando la participación es cero. Ningún municipio real está ahí; es solo el punto donde arranca la recta.

Dos números, siempre con unidades

- El **Intercept**: la ventaja que predice el modelo cuando la participación es cero. Ningún municipio real está ahí; es solo el punto donde arranca la recta.
- El coeficiente de **participacion**: -0.287 . Por cada punto porcentual más de participación, la ventaja de la coalición cae, en promedio, 0.29 puntos porcentuales.

Dos números, siempre con unidades

- El **Intercept**: la ventaja que predice el modelo cuando la participación es cero. Ningún municipio real está ahí; es solo el punto donde arranca la recta.
- El coeficiente de **participacion**: -0.287 . Por cada punto porcentual más de participación, la ventaja de la coalición cae, en promedio, 0.29 puntos porcentuales.

El salto

Ese número dejó de ser una salida de consola en el momento en que le pusiste unidades y lo convertiste en una oración completa. Ahora es una afirmación sobre México que alguien más puede leer y discutir.

Una recta con nombre

Dos funciones para la misma pregunta

Leer una tabla sin haberla derivado

Un segundo modelo, y la tentación que resistimos

Correlación no es causa

Ejercicio

Por qué dos funciones para lo mismo

- `lm()` viene con R, sin instalar nada: es la que vas a ver en Estadística I y la que cualquiera reconoce de inmediato.

Por qué dos funciones para lo mismo

- `lm()` viene con R, sin instalar nada: es la que vas a ver en Estadística I y la que cualquiera reconoce de inmediato.
- `feols()`, del paquete `fixest`, ajusta la misma recta y además calcula, de fábrica, un error estándar que no asume que la dispersión es igual en todo el rango de x .

Por qué dos funciones para lo mismo

- `lm()` viene con R, sin instalar nada: es la que vas a ver en Estadística I y la que cualquiera reconoce de inmediato.
- `feols()`, del paquete `fixest`, ajusta la misma recta y además calcula, de fábrica, un error estándar que no asume que la dispersión es igual en todo el rango de x .
- La regla del curso: `lm()` se enseña porque la vas a necesitar. Lo que se **reporta** como resultado final es `feols()` con un error estándar robusto.

La misma recta, con feols()

```
library(fixest)

modelo_1_robusto <- feols(
  ventaja_shh ~ participacion,
  data = municipios,
  vcov = "hetero")

summary(modelo_1_robusto)
```

`vcov = "hetero"` pide el error estándar robusto. **Heterocedasticidad** la formalizas en Estadística; aquí solo la nombras y la pides.

Lo que cambia y lo que no cambia

- El coeficiente de `participacion` es **exactamente el mismo** en los dos ajustes: -0.287 . La recta es la misma recta.

Lo que cambia y lo que no cambia

- El coeficiente de `participacion` es **exactamente el mismo** en los dos ajustes: -0.287 . La recta es la misma recta.
- Lo que cambia es el error estándar, el número entre paréntesis: dice qué tan segura es la estimación, no cambia la estimación misma.

Lo que cambia y lo que no cambia

- El coeficiente de `participacion` es **exactamente el mismo** en los dos ajustes: -0.287 . La recta es la misma recta.
- Lo que cambia es el error estándar, el número entre paréntesis: dice qué tan segura es la estimación, no cambia la estimación misma.
- Aquí el error clásico (0.045) y el robusto (0.044) casi no difieren: en este modelo, la heterocedasticidad no era severa.

Cuando algo falla

Error: `could not find function "feols"`

Traducción: «no encuentro ninguna función con ese nombre».

Casi siempre falta correr `library(fixest)`, aunque ya hayas cargado `tidyverse`. Corre esa línea y vuelve a intentar.

Una recta con nombre

Dos funciones para la misma pregunta

Leer una tabla sin haberla derivado

Un segundo modelo, y la tentación que resistimos

Correlación no es causa

Ejercicio

modelsummary(): la tabla, no la consola

```
modelsummary(  
  list("Modelo 1" = modelo_1_robusto),  
  stars = TRUE)
```

Nunca copies y pegues `summary()` como si fuera una tabla: es fácil que se te vaya un número, y no tiene el formato de un trabajo final.

Cómo se lee, en cuatro palabras

- Cada **fila** es una variable.

Cómo se lee, en cuatro palabras

- Cada fila es una variable.
- El número de arriba es el coeficiente; el de abajo, entre paréntesis, es el error estándar.

Cómo se lee, en cuatro palabras

- Cada fila es una variable.
- El número de arriba es el coeficiente; el de abajo, entre paréntesis, es el error estándar.
- Los asteriscos dicen qué tan lejos está el coeficiente de cero, no qué tan importante es.

Cómo se lee, en cuatro palabras

- Cada **fila** es una variable.
- El número de arriba es el coeficiente; el de abajo, entre paréntesis, es el error estándar.
- Los asteriscos dicen qué tan lejos está el coeficiente de cero, no qué tan importante es.
- Abajo, **N** y **R2** describen el modelo completo, no una variable sola.

La humildad de los asteriscos

Con 2,473 municipios, hasta una relación débil deja de parecer casualidad estadística: `participacion` tiene tres asteriscos.

Pero el R^2 de ese modelo es apenas 0.016: la participación explica un pedazo minúsculo de por qué la ventaja cambia de un municipio a otro.

La humildad de los asteriscos

Con 2,473 municipios, hasta una relación débil deja de parecer casualidad estadística: `participacion` tiene tres asteriscos.

Pero el R^2 de ese modelo es apenas 0.016: la participación explica un pedazo minúsculo de por qué la ventaja cambia de un municipio a otro.

Una regla que te llevas

Un coeficiente pequeño con muchos asteriscos no necesariamente importa.
Uno grande sin asteriscos no necesariamente no importa.

Una recta con nombre

Dos funciones para la misma pregunta

Leer una tabla sin haberla derivado

Un segundo modelo, y la tentación que resistimos

Correlación no es causa

Ejercicio

Un segundo modelo: sumamos pct_mc

```
modelo_2 <- feols(  
  ventaja_shh ~ participacion + pct_mc,  
  data = municipios,  
  vcov = "hetero")  
  
modelsummary(  
  list("Modelo 1" = modelo_1_robusto,  
        "Modelo 2" = modelo_2),  
  stars = TRUE)
```

Esto es lo que regresa

	Modelo 1	Modelo 2
(Intercept)	62.462*** (2.830)	70.386*** (2.635)
participacion	-0.287*** (0.044)	-0.176*** (0.043)
pct_mc		-1.670*** (0.069)
N	2473	2473
R ²	0.016	0.187

*** p < 0.001. Errores estándar robustos entre paréntesis. Fuente: INE, cálculos 2024, por municipio.

El coeficiente se movió: ¿qué significa?

- `participacion` pasó de -0.29 a -0.18 al agregar `pct_mc`.

El coeficiente se movió: ¿qué significa?

- `participacion` pasó de -0.29 a -0.18 al agregar `pct_mc`.
- Se movió porque, en el territorio, la participación y el voto de Movimiento Ciudadano no son independientes entre sí.

El coeficiente se movió: ¿qué significa?

- `participacion` pasó de -0.29 a -0.18 al agregar `pct_mc`.
- Se movió porque, en el territorio, la participación y el voto de Movimiento Ciudadano no son independientes entre sí.
- ¿Qué significa exactamente que se haya movido? No lo vamos a contestar hoy.

La tentación que resistimos

- Sin un diseño que aísle qué está causando qué, agregar variables no acerca a la causalidad: solo cambia el número.

La tentación que resistimos

- Sin un diseño que aísle qué está causando qué, agregar variables no acerca a la causalidad: solo cambia el número.
- La especificación del proyecto final usa **una sola** variable explicativa, a propósito.

La tentación que resistimos

- Sin un diseño que aísle qué está causando qué, agregar variables no acerca a la causalidad: solo cambia el número.
- La especificación del proyecto final usa **una sola** variable explicativa, a propósito.
- Un modelo con más variables no es automáticamente un modelo más honesto.

La promesa del proyecto final

`ventaja_shh`, la misma variable de hoy, va a reaparecer en la sesión 11 —pero del otro lado de la ecuación—.

Lo que viene

```
feols(pct_bloque_a ~ ventaja_shh,  
      data = municipios, vcov = "hetero")
```

Esa línea la vas a escribir casi tal cual en la sesión 11.

Una recta con nombre

Dos funciones para la misma pregunta

Leer una tabla sin haberla derivado

Un segundo modelo, y la tentación que resistimos

Correlación no es causa

Ejercicio

Una historia: hijas y votaciones

Legisladores de Estados Unidos con más hijas tienden a votar más a favor de temas relacionados con mujeres que legisladores con más hijos. ¿Tener hijas **causa** ese voto?

- Antes de aceptarlo, pregúntate qué otra historia produce la misma correlación sin que haya una causa directa.

Una historia: hijas y votaciones

Legisladores de Estados Unidos con más hijas tienden a votar más a favor de temas relacionados con mujeres que legisladores con más hijos. ¿Tener hijas **causa** ese voto?

- Antes de aceptarlo, pregúntate qué otra historia produce la misma correlación sin que haya una causa directa.
- Las familias grandes podrían compartir otras características —ingreso, religión, región— que también predicen ese voto.

Una historia: hijas y votaciones

Legisladores de Estados Unidos con más hijas tienden a votar más a favor de temas relacionados con mujeres que legisladores con más hijos. ¿Tener hijas **causa** ese voto?

- Antes de aceptarlo, pregúntate qué otra historia produce la misma correlación sin que haya una causa directa.
- Las familias grandes podrían compartir otras características —ingreso, religión, región— que también predicen ese voto.
- El número de hijas sería, en ese caso, un compañero de viaje de la causa real, no la causa.

La regla que te llevas

El salto

Cada vez que un coeficiente sale distinto de cero, pregúntate qué otra historia, además de «X causa Y», explica el mismo número. Esa pregunta no la contesta R. La contestas tú.

El proyecto final lo dice con todas sus letras: que dos cosas coincidan en el territorio no dice cuál produce cuál.

Una recta con nombre

Dos funciones para la misma pregunta

Leer una tabla sin haberla derivado

Un segundo modelo, y la tentación que resistimos

Correlación no es causa

Ejercicio

Quince minutos, tres niveles

- **Calentamiento** — la misma recta, cambiando qué se explica.
- **De verdad** — ¿la participación le pega igual a todos los bloques?
- **Si te sobra tiempo** — qué es, de verdad, un error estándar robusto.

El archivo es `09_ejercicio.R`. La solución se publica al terminar la sesión.

Lo que ya sabemos hacer

- Ajustar una regresión con `lm()` y con `feols()`, y leer sus dos números con unidades.
- Armar y leer una tabla de `modelsummary()` sin copiar y pegar la consola.
- Explicar, en una oración, por qué agregar una variable no es lo mismo que acercarse a la causalidad.

LA SEMANA QUE VIENE

Que otro pueda repetirlo

Todo lo que hiciste en estas nueve horas va a vivir en un documento que cualquiera puede abrir y correr de nuevo, sin tu computadora. Vamos a escribirlo con Quarto y a subirlo para que exista fuera de tu laptop.